

Análisis Estadístico I

Estadística Descriptiva

Natalia SALABERRY

Estadística Descriptiva



Nos permite describir un conjunto de datos para luego sacar conclusiones y así obtener información acerca del suceso al cual están asociados los datos.



Dato



Es la menor unidad de representación de un suceso o parte de el.
Surge como consecuencia de una observación o medición del suceso.



Ejemplo:

Objetivo obtener información de desempleo en una fábrica

Datos: cantidad de empleados activos y despedidos de la fábrica

Suceso: despidos en la fábrica

Medición: representación de los despidos.

Por ejemplo tasa de desempleo =

$$\text{empleados despedidos} / (\text{empleados activos} + \text{empleados despedidos})$$

Información: la tasa de desempleo es x% en la fábrica

Metodología

Conjunto de pasos que me permitirán obtener información
a partir de los datos

Diseño

Descripción

Inferencia

Conclusión

del plan y desarrollo
del proceso de
investigación

de los datos, a
través de la
exploración

de un suceso, a
partir de los
datos

toma de
decisiones
entorno al
suceso

1. Organizar los datos
2. Procesar los datos
3. Obtener características relevantes de los datos
4. Presentar los resultados

Descripción

Los Los datos pueden ser de diferente tipo:

- **Cualitativos:** representan una cualidad del objeto o persona medida. Por ejemplo: Color de ojos. A su vez estos pueden ser de dos tipos:
 - **Nominales:** no poseen una jerarquía y permiten identificar a partir de una categoría. Por ejemplo: Cantidad de personas según profesión que ejercen (actuuario, economista, entre otros)
 - **Ordinales:** poseen un orden dentro de la categoría. Por ejemplo: Cantidad de personas según nivel de formación alcanzado (1-primario, 2- secundario, y así sucesivamente)
- **Cuantitativos:** son datos numéricos que surgen de una medición o conteo. Por ejemplo cantidad personas, edad de las personas, entre otros. A su vez estos pueden ser de dos tipos:
 - **Discretos:** generalmente surgen de un conteo. Por ejemplo: Cantidad de personas.
 - **Continuos:** generalmente surgen de una medición. Por ejemplo: nivel de ingreso de personas

Descripción

Según el tipo de datos, se requiere saber su cantidad y porcentaje. Entonces surgen dos conceptos:

Frecuencia Absoluta

f_i



Cantidad de veces que aparece un valor dentro del conjunto de datos

Frecuencia Relativa

f_{ri}



Proporción de veces que aparece un valor dentro del conjunto de datos

También, es útil poder contar con la frecuencia de valores menores o iguales a un determinado valor. Para ello se definen dos conceptos:

Frecuencia Absoluta
acumulada

F_i



Es la suma de las frecuencias de todos los valores menores a x_i

Frecuencia Relativas
acumulada

F_{ri}



Es la suma de las frecuencias relativas de todos los valores menores a x_i

Descripción

x		f_i	$f_{r_i} = \frac{f_i}{n}$
2			
3	2 -> aparece 2 veces	2	2/5
4	3 -> aparece 1 veces	1	1/5
5	4 -> aparece 1 veces	1	1/5
2	5 -> aparece 1 vez	1	1/5

Ejemplo

x_i	f_i	F_i	f_{r_i}	F_{r_i}	F_{r_i} en %
2	2	2	2/5	2/5	40,0
3	1	3	1/5	3/5	60,0
4	1	4	1/5	4/5	80,0
5	1	5	1/5	5/5	100

Descripción

A partir de las frecuencia relativa y frecuencia absoluta podemos determinar la **distribución de frecuencia relativa y la distribución de frecuencia absoluta**. Estas nos permitirán conocer características sobre como se distribuyen los datos.

Normalmente surgen de realizar un análisis gráfico. Para ello se utilizan los siguientes gráficos:

- Gráfico de barras
- Gráfico de Polígonos
- Gráfico circulares
- Histograma
- Boxplot

Frecuencia absoluta acumulada




Gráfico de barras

Frecuencia relativa acumulada




Gráfico de polígono

Frecuencia absoluta en %




Gráfico circulares

Descripción

La descripción de los datos puede realizarse a través de diferentes medidas. Estas proporcionarán características que permitirán tener un mayor conocimiento de los mismos.

Hay tres tipos de medidas:

- **Medias de posición:** refieren a entorno de que valor se encuentran distribuidos los datos
 - **De tendencia central:** indican el centro de la distribución de frecuencia
 - **De tendencia no central:** brindan información de ciertos valores, no necesariamente centrales
- **Medias de dispersión:** refieren a que tan dispersos se encuentran los datos respecto de su valor central
- **Medias de forma:** refieren a la forma que tiene la distribución de los datos. Permiten saber si hay tendencia de que los datos se agrupen hacia uno de los lados respecto de un valor central y la probabilidad de ocurrencia del valor central

Descripción

Medias de posición – De tendencia central

- **MEDIA MUESTRAL:** Es el promedio simple de los datos. Es muy sensible a valores atípicos siendo aquellos que se alejan del comportamiento “normal” de los datos

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n}$$

- **MEDIANA:** Es el valor central (mitad=50%) cuando los datos se encuentran ordenados de manera creciente.

Para obtener su valor se debe primero calcular:

Distancia = $k \cdot (n-1)$ donde k es el porcentaje que en este caso es 0,5

Si:

Distancia = número entero $\Rightarrow$ es la posición. Buscaré en el índice de mis datos dicha posición y me fijare el valor que toma la variable siendo este el valor de la mediana

Distancia = número decimal $\Rightarrow$ debo interpolar. El resultado de esta operación será el valor de la mediana

- **MODA:** Es el valor más frecuente, es decir, el de mayor frecuencia absoluta y relativa. Si dos o más valores son los de mayor frecuencia entonces estamos frente a una distribución multimodal

$$X_{mo}$$

Descripción

Medidas de Posición

De tendencia central

Ejemplo

x
2
3
4
5
2
16

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n} = \frac{(2+3+4+5+2)}{5} = 3,2$$

$X_{mo}=2$ siendo el valor que se repite más veces

Para calcular la mediana

Distancia = $k \cdot (n-1)$ donde k es el porcentaje

= $0,5 \cdot (5-1) = 2$ si es entero directamente es la posición =>

$X_2=3$

Por lo tanto, la mediana es igual a 3


Posición	x
0	2
1	2
2	3
3	4
4	5
	16

Descripción

Medias de posición – De tendencia no central

- **PERCENTILES:** Permiten saber el porcentaje de observaciones que se encuentran por debajo de un valor determinado y el $(100-k)\%$ por encima (dividen la distribución en 100 partes iguales). Los datos siempre deben estar ordenados.

$$P_k$$



Para hallar su valor, debo seguir el siguiente procedimiento:

Distancia = $k \cdot (n-1)$ donde k es el porcentaje que en este caso es 0,5

Si:

Distancia = número entero $\Rightarrow$ es la posición. Buscaré en el índice de mis datos dicha posición y me fijaré el valor que toma la variable siendo este el valor de la mediana

Distancia = número decimal $\Rightarrow$ debo interpolar. El resultado de esta operación será el valor de la mediana

- **CUARTILES:** dividen la distribución de frecuencias en cuatro partes iguales. Para hallar su valor, opero igual que con los percentiles

Descripción

Medias de posición – De tendencia central

- **DECILES:** dividen la distribución de frecuencias en diez partes iguales.

$$D_k$$

Para hallar su valor, opero igual que con los percentiles

- Equivalencias

$$P_{50} = Q_2 = D_5 = X_{me}$$

$$P_{10} = D_1$$

$$P_{25} = Q_1$$

$$P_{20} = D_2 \text{ y así sucesivamente}$$

$$P_{75} = Q_3$$

Descripción

Medidas de Posición

De tendencia no central

Ejemplo

Orden	X
0	2
1	2
2	3
3	4
4	5

Decil 5: Distancia = $k \cdot (n-1) = 0,5 \cdot (5-1) = 2$ si es entero directamente es la posición $\Rightarrow X_2 = 3$ Entonces, el decil 5 es igual a 3

Cuartil 2: Distancia = $k \cdot (n-1) = 0,5 \cdot (5-1) = 2$ si es entero directamente es la posición $\Rightarrow X_2 = 3$ Entonces, el cuartil 2 es igual a 3

Percentil 50: Distancia = $k \cdot (n-1) = 0,5 \cdot (5-1) = 2$ si es entero directamente es la posición $\Rightarrow X_2 = 3$ Entonces, el percentil 50 es igual a 3

Y además coinciden con la mediana, lo cual es correcto ya que en todos los casos estoy buscando el valor que se corresponde con la mitad de la distribución de los datos

Descripción

Medidas de Posición

De tendencia no central

Posición	X
0	2
1	2
2	3
3	4
4	5

Por ejemplo, si queremos calcular P_{70} , se calcula la distancia

$$Distancia = k * (n - 1) = 0,70 * (5 - 1) = 2,8$$

=> como no es entero, se debe interpolar

Interpolación: $X_{parteentera} + Partedecimal * (X_{posterior} - X_{parteentera})$

$$X_{parteenterea} = X_2 = 3 \quad X_{posterior} = X_{parteenterea+1} = X_3 = 4$$

ParteDecimal 0,8

Luego $3 + 0,8 * (4 - 3) = 3 + [0,8 * (1)] = 3,8 \Rightarrow P_{70} = 3,8$ siendo el valor del pecentil 70

Descripción

Ejemplo

Dadas las ventas de supermercados entre enero y noviembre 2022, se busca generar información para responder las siguientes preguntas:

- A) ¿Cuál es el monto promedio vendido por los supermercados?
- B) ¿En qué mes el monto vendido alcanza el 50% de las ventas?
- C) ¿En qué mes el monto vendido alcanza el 75% de las ventas?
- D) ¿En qué mes el monto vendido es mínimo para el 25% superior de las ventas?
- E) ¿En qué mes el monto vendido es máximo para el 25% de las ventas?

Lo primero es observar si los datos están ordenados (siempre miro la variable objetivo que en este caso son las Ventas)

Período	VENTAS en Millones de pesos
ene-22	\$ 23,33
feb-22	\$ 24,21
mar-22	\$ 29,38
abr-22	\$ 30,03
may-22	\$ 31,50
jun-22	\$ 33,92
jul-22	\$ 39,73
ago-22	\$ 37,06
sep-22	\$ 38,92
oct-22	\$ 41,67
nov-22	\$ 46,61

Descripción

Ejemplo

Como en agosto baja el valor (es más chico que el anterior) entonces los ordeno y establezco posición

Posición	Período	VENTAS en Millones de pesos
0	ene-22	\$ 23,33
1	feb-22	\$ 24,21
2	mar-22	\$ 29,38
3	abr-22	\$ 30,03
4	may-22	\$ 31,50
5	jun-22	\$ 33,92
6	ago-22	\$ 37,06
7	sep-22	\$ 38,92
8	jul-22	\$ 39,73
9	oct-22	\$ 41,67
10	nov-22	\$ 46,61
	Total	\$ 376,36

A) ¿Cuál es el monto **promedio** vendido por los supermercados?

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n} = \frac{376,36}{11} = 34,21$$

El monto promedio vendido en el período por los supermercados es \$34,21 (en millones)

B) ¿En qué **mes** el monto vendido **alcanza el 50%** de las ventas?

Al preguntar “alcanza el 50%” => Mediana (o Percentil 50)

Entonces, calculo distancia

Distancia = $k \cdot (n-1) = 0,5 \cdot (11-1) = 5$ => como es entero, es directamente la posición => $X_5 = X_{me} = \$33,92$ que se corresponde a Junio 2022

El mes donde se alcanza el 50% de las ventas es Junio 2022

Descripción

Ejemplo

Como en agosto baja el valor (es más chico que el anterior) entonces los ordeno y establezco posición

Posición	Período	VENTAS en Millones de pesos
0	ene-22	\$ 23,33
1	feb-22	\$ 24,21
2	mar-22	\$ 29,38
3	abr-22	\$ 30,03
4	may-22	\$ 31,50
5	jun-22	\$ 33,92
6	ago-22	\$ 37,06
7	sep-22	\$ 38,92
8	jul-22	\$ 39,73
9	oct-22	\$ 41,67
10	nov-22	\$ 46,61
	Total	\$ 376,36

C) ¿En qué mes el monto vendido alcanza el 75% de las ventas?

Al preguntar "alcanza el 75%" => Percentil 75

Entonces, calculo distancia

$Distancia = k * (n - 1) = 0,75 * (11 - 1) = 7.5 \Rightarrow$ como no es entero, interpolo

Interpolación: $X_{parteentera} + Partedecimal * (X_{posterior} - X_{parteentera})$

$X_{parteentera} = X_7 = 38,92$ $X_{posterior} = X_{parteentera+1} = X_8 = 39,73$
ParteDecimal 0,5

Luego $38,92 + 0,5 * (39,73 - 38,92) = 38,92 + [0,5 * (0,81)] = 39,325$
 $\Rightarrow P_{75} = \$39,325 \Rightarrow$ busco el más cercano

El mes con el monto vendido que alcanza el 75% de las ventas es Julio 2022

Descripción


Ejemplo

Como en agosto baja el valor (es más chico que el anterior) entonces los ordeno y establezco posición

Posición	Período	VENTAS en Millones de pesos
0	ene-22	\$ 23,33
1	feb-22	\$ 24,21
2	mar-22	\$ 29,38
3	abr-22	\$ 30,03
4	may-22	\$ 31,50
5	jun-22	\$ 33,92
6	ago-22	\$ 37,06
7	sep-22	\$ 38,92
8	jul-22	\$ 39,73
9	oct-22	\$ 41,67
10	nov-22	\$ 46,61
	Total	\$ 376,36

D) ¿En qué mes el monto vendido es **mínimo** para el **25% superior** de las ventas?

Si los datos que ya están ordenados fuesen representados en una recta numérica



El X75 es valor mínimo del 25% superior de las ventas de mayor monto

Entonces,

$\Rightarrow P_{75} = \$39,325 \Rightarrow$ siendo el mismo que en el punto C.

El mes en el cual es monto vendido es mínimo para el 25% superior de las ventas es Julio 2022

Descripción

Ejemplo

Como en agosto baja el valor (es más chico que el anterior) entonces los ordeno y establezco posición

Posición	Período	VENTAS en Millones de pesos
0	ene-22	\$ 23,33
1	feb-22	\$ 24,21
2	mar-22	\$ 29,38
3	abr-22	\$ 30,03
4	may-22	\$ 31,50
5	jun-22	\$ 33,92
6	ago-22	\$ 37,06
7	sep-22	\$ 38,92
8	jul-22	\$ 39,73
9	oct-22	\$ 41,67
10	nov-22	\$ 46,61
	Total	\$ 376,36

E) ¿En qué mes el monto vendido es máximo para el 25% de las ventas?

Al preguntar “máximo para el 25%” (alcanza) => Percentil 25 ya que es valor máximo para el 25%

Entonces, calculo distancia

$Distancia = k * (n - 1) = 0,25 * (11 - 1) = 2,5$ => como no es entero, interpolo

Interpolación: $X_{parteentera} + ParteDecimal * (X_{posterior} - X_{parteentera})$

$X_{parteentera} = X_2 = 29,38$ $X_{posterior} = X_{parteentera+1} = X_3 = 30,03$
ParteDecimal 0,5

Luego $29,38 + 0,5 * (30,03 - 29,38) = 29,38 + [0,5 * (0,65)] = 29,705$
=> $P_{25} = \$29,705$ => busco el más cercano => 30,03

El mes en el que monto de las ventas alcanza el 25% es Abril 2022

Descripción

Medias de dispersión

- **RANGO:** Diferencia entre el máximo y mínimo valor de los datos (longitud del intervalo)

$$Rango = x_{max} - x_{min}$$

- **RANGO INTERCUARTILICO:** Longitud del intervalo donde se encuentran el 50% de los datos.

$$RIC = Q_3 - Q_1 = P_{75} - P_{25}$$

- **VARIANZA MUESTRAL:** indica cuanto se alejan los datos de su media en términos cuadráticos

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n - 1}$$

- **DESVÍO ESTANDAR:** indica cuanto se alejan los datos de su media en la misma unidad de medida que los datos. Se calcula como la raíz cuadrada de la varianza muestral.

- **COEFICIENTE DE VARIACIÓN:** Mide la relación entre la media y el desvío de la muestra. En general es útil para comparar dos o más conjuntos de datos. Cuanto mayor es el CV, mayor es la dispersión y por lo tanto menos representativa es la media

$$CV = \frac{s}{\bar{X}}$$

Descripción



Medidas de Dispersión

Ejemplo

$$RIC = P_{75} - P_{25} = X_3 - X_1 = 4 - 2 = 2$$

P_{75} : Distancia = $k \cdot (n-1) = 0,75 \cdot (5-1) = 3$ como es entero entonces directamente es la posición $\Rightarrow P_{75} = X_3 = 4$

P_{25} : Distancia = $k \cdot (n-1) = 0,25 \cdot (5-1) = 1$ como es entero entonces directamente es la posición $\Rightarrow P_{25} = X_1 = 2$

Orden	X
0	2
1	2
2	3
3	4
4	5

Descripción

Medidas de Dispersión

Ejemplo

Orden	X	$(x_i - \bar{X})^2$
0	2	1,44
1	2	1,44
2	3	0,04
3	4	0,64
4	5	3,24
	16	6,8

$$Rango = x_{max} - x_{min} = 5 - 2 = 3$$

$$S^2 = \frac{6,8}{5 - 1} = 1,7 \quad S = \sqrt{1,7} = 1,3$$

$$CV = \frac{S}{\bar{X}} = \frac{1,3}{3,2} = 0,41$$

En general si es menor de 0,5 entonces se considera chico

Descripción

Ejemplo

Continuando con las ventas de supermercados entre enero y noviembre 2022, se buscar generar información para responder las siguientes preguntas:

F) ¿Entre qué valores se encuentran las ventas de los supermercados?

G) ¿Entre qué meses se encuentra el 50% de las ventas y cuál es el monto acumulado?

H) ¿Cuál es la variabilidad de montos vendidos en el período dado?

I) ¿Cuál es la variabilidad de montos vendidos en la misma unidad de medida que los montos en el período dado?

J) ¿Recomendaría utilizar la media de los montos vendidos como medida a ser informada?

Período	VENTAS en Millones de pesos
ene-22	\$ 23,33
feb-22	\$ 24,21
mar-22	\$ 29,38
abr-22	\$ 30,03
may-22	\$ 31,50
jun-22	\$ 33,92
jul-22	\$ 39,73
ago-22	\$ 37,06
sep-22	\$ 38,92
oct-22	\$ 41,67
nov-22	\$ 46,61

Lo primero es observar si los datos están ordenados (siempre miro la variable que en este caso es las Ventas)

Descripción

Ejemplo

Como en agosto baja el valor (es más chico que el anterior) entonces los ordeno y establezco posición

Posición	Período	VENTAS en Millones de pesos
0	ene-22	\$ 23,33
1	feb-22	\$ 24,21
2	mar-22	\$ 29,38
3	abr-22	\$ 30,03
4	may-22	\$ 31,50
5	jun-22	\$ 33,92
6	ago-22	\$ 37,06
7	sep-22	\$ 38,92
8	jul-22	\$ 39,73
9	oct-22	\$ 41,67
10	nov-22	\$ 46,61
	Total	\$ 376,36

F) ¿Entre qué valores se encuentran las ventas de los supermercados?
Si me preguntan “Entre que valores” entonces se trata de un **rango** (intervalo) que tiene un valor mínimo y un valor máximo
El valor mínimo es 23,33 y el valor máximo 46,61
Las ventas para el período se encuentran entre \$23,33 y \$46,61 millones

G) ¿Entre qué meses se encuentra el 50% de las ventas y cuál es el monto acumulado?
Si me preguntan “Entre que meses” entonces se trata de un **intervalo** donde acumula el 50%

RIC= P75-P25 => tengo acumulado el 50% (75%-25%=50%)

Utilizando los valores ya calculados en C y E, entonces:

Monto acumulado = P75-P25= \$39,325 - \$29,705 = \$9,62

Entre los meses de abril y julio se encuentra el 50% de las ventas que acumula un monto vendido de \$9,62 millones

Descripción

Ejemplo

Posición	Período	VENTAS en Millones de pesos	$(x_i - \bar{X})^2$
0	ene-22	\$ 23,33	\$ 118,47
1	feb-22	\$ 24,21	\$ 100,09
2	mar-22	\$ 29,38	\$ 23,37
3	abr-22	\$ 30,03	\$ 17,51
4	may-22	\$ 31,50	\$ 7,37
5	jun-22	\$ 33,92	\$ 0,09
6	ago-22	\$ 37,06	\$ 8,10
7	sep-22	\$ 38,92	\$ 22,14
8	jul-22	\$ 39,73	\$ 30,42
9	oct-22	\$ 41,67	\$ 55,58
10	nov-22	\$ 46,61	\$ 153,65
	Total	\$ 376,36	\$ 536,79

H) ¿Cuál es la **variabilidad** de montos vendidos en el período dado?

Si me preguntan por la “variabilidad” y no se aclara nada más, entonces es el concepto es varianza

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n-1} = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{11-1} = \frac{536,79}{10} = 53,679$$

La variabilidad de montos vendidos es de \$53,679 millones

I) ¿Cuál es la **variabilidad** de montos vendidos **en la misma unidad de medida** que los montos en el período dado?

A diferencia del punto anterior ahora me aclaran “en la misma unidad”, entonces es el desvío

$$S = \sqrt{S^2} = \sqrt{53,679} = 7,326595389 \approx 7,33$$

La variabilidad de montos vendidos en la misma unidad de medida que las ventas es \$7,33 millones

J) ¿Recomendaría utilizar la media de los montos vendidos como medida a ser informada?

Lo que me permite saber si la media es representativa (y por tanto determinar si es recomendable informarla) es el


$$CV = \frac{S}{\bar{X}} = \frac{7,33}{34,21} = 0,214264834 \approx 0,21 \Rightarrow \text{Al ser un valor bajo, es recomendable informar la media}$$

De hecho, si se observa $\bar{X} = 34,21$ y $X_{me} = \$33,9$ son valores muy similares.

Descripción


Histograma

Un histograma es una representación visual de los datos agrupados en intervalos. Los intervalos se denominan intervalos de clase y su forma gráfica es un rectángulo. Al ser un intervalo tendrá un límite inferior y un límite superior por lo que los datos serán asignados entre estos límites, conformándose así varios intervalos de clase que hacen a la distribución total de los datos. De este modo permitirá observar gráficamente la forma que toma la distribución y su comportamiento. Además, cada intervalo de clase tendrá una marca de clase que es el punto medio del intervalo (es decir, Límite inferior + Límite superior dividido 2). La amplitud del intervalo de clase vendrá dada por la diferencia entre el límite superior y el límite inferior. Luego, el área correspondiente a cada intervalo de clase representa la frecuencia absoluta (o relativa) de la clase. Observaremos que las sumas de las áreas de los rectángulos es 1 (o 100 %).



Descripción

Boxplot



Descripción

Medias de forma

- **COEFICIENTE DE ASIMETRÍA:** Permite saber el tipo de asimetría de una distribución, es decir, cuan desviados se encuentran los datos respecto de la media

$$A_s = \frac{n}{(n-1) * (n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{X}}{S} \right)^3$$

Si $A_s = 0$ distribución simétrica

Si $A_s > 0$ asimétrica positiva

Si $A_s < 0$ asimétrica negativa

Si $x_{mo} < x_{me} < \bar{X} \Rightarrow$ asimétrica positiva (sesgo a derecha)


Si $x_{mo} = x_{me} = \bar{X} \Rightarrow$ simétrica

Si $x_{mo} > x_{me} > \bar{X} \Rightarrow$ asimétrica negativa (sesgo a izquierda)

Descripción


Histograma

La simetría o asimetría es fácilmente observable en un histograma




Sesgo a derecha:

- Cola de la distribución a derecha.
- Mayor concentración de datos a izquierda



Sesgo a izquierda:

- Cola de la distribución a izquierda.
- Mayor concentración de datos a derecha





Sin sesgo:

- Colas a ambos lados.
- Mayor concentración de datos en el centro

Descripción

También podemos ver la simetría o asimetría en un boxplot
(siempre girar un boxplot vertical siempre hacia la derecha)



Descripción

Medias de forma

- **COEFICIENTE DE CURTOSIS:** Permite saber cómo es la concentración de datos (cuán puntiaguda es la forma de la distribución)

$$k = \left[\frac{n * (n + 1)}{(n - 1) * (n - 2) * (n - 3)} * \sum_{i=1}^n \left(\frac{x_i - \bar{X}}{S} \right)^4 \right] - \frac{3 * (n - 1)^2}{(n - 2) * (n - 3)}$$

Si $k=3$ mesocúrtica

Si $k > 3$ leptocúrtica

Si $k < 3$ platicúrtica

Si la distribución es muy puntiaguda entonces es leptocúrtica


Si la distribución es chata entonces es platicúrtica

Si la distribución no es ni muy chata ni muy puntiaguda entonces es mesocúrtica

Descripción

Histograma

En un histograma podemos observar la curtosis (respecto de la concentración de los datos alrededor de un valor central – generalmente la media de la distribución-)



Descripción

Medidas de Forma

Ejemplo

Continuando con el ejemplo de la clase anterior

x	$((x_i - \bar{X})/S)^3$
2	-0,786527082
2	-0,786527082
3	-0,003641329
4	0,233045061
5	2,654528903
16	1,310878471

$$A_s = \frac{n}{(n-1) * (n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{X}}{S} \right)^3 = \frac{5}{(5-1) * (5-2)} * 1,310878471$$

$$= 0,546199362 > 0 \Rightarrow \text{asimétrica positiva}$$

x	$((x_i - \bar{X})/S)^4$
2	0,726024999
2	0,726024999
3	0,000560204
4	0,143412346
5	3,675501558
16	5,271524106


$$\left[\frac{n * (n+1)}{(n-1) * (n-2) * (n-3)} * \sum_{i=1}^n \left(\frac{x_i - \bar{X}}{S} \right)^4 \right] - \frac{3 * (n-1)^2}{(n-2) * (n-3)}$$

$$= \left[\frac{5 * (5+1)}{(5-1) * (5-2) * (5-3)} * 5,271524106 \right] - \frac{3 * (5-1)^2}{(5-2) * (5-3)}$$

$$= 6,589405133 - 8 = -1,410594867 < 3 \Rightarrow \text{platicúrtica}$$

Descripción


Podemos comparar ambos gráficos del siguiente modo:



El histograma muestra una asimetría a derecha. Es decir, mayor concentración de datos a izquierda y cola de distribución a derecha.

Tales características también las vemos representadas en el boxplot: la concentración del 50% de los datos (caja del boxplot) se encuentra a izquierda (concentración de datos a izquierda)). Y el bigote superior es más largo a derecha (cola de distribución a derecha). Y además se encuentran los valores atípicos, que en el histograma se ven representados en las últimas barras de la derecha (de menor tamaño)


Descripción



En el histograma se observa simetría.

En el bloxplot también, ya que la caja se encuentra en el medio de todo el largo (desde bigote inferior hasta bigote superior) del boxplot.


Además, la mediana se encuentra en el centro de la caja de boxplot lo que indica simetría.



En el histograma se observa asimetría a izquierda.

En el bloxplot también, ya que la caja se encuentra hacia la derecha y el bigote inferior es más largo que el superior.

Además, la mediana se encuentra más cercana al límite superior de la caja (Q3) lo que indica asimetría a izquierda.



En el histograma se observa asimetría a derecha.


En el bloxplot también, ya que la caja se encuentra hacia la izquierda y el bigote superior es más largo que el inferior.

Además, la mediana se encuentra más cercana al límite inferior de la caja (Q1) lo que indica asimetría a derecha.

Descripción

EJEMPLO: Observando el siguiente histograma de la cotización diaria de cierre del Bitcoin entre 1/7/2023 y 1/7/2024 en dólares, responder acerca de las siguientes afirmaciones **justificando** adecuadamente su respuesta.

Histograma Cotización de cierre de Bitcoin



A) “Puede afirmarse que la distribución de la cotización del BTC es asimétrica positiva”

Falso, justificar

B) “Dado un valor del coeficiente de curtosis de -1,48 entonces la distribución es platicúrtica”


Verdadero, justificar

C) “Podría decirse que no hay valores atípicos”

Verdadero, justificar

Descripción

EJEMPLO: Se tomaron las cotizaciones de Google (GOOG) y Amazon (AMZN) para el período 1/6/2023 a 1/7/2023. Los boxplots correspondientes se encuentran en la siguiente imagen. Se dispone además de algunas medidas estadísticas.



Estadística	N	MEDIA	MEDIANA	DESVÍO	MIN	MAX
AMZN	21.0	126.4	126.6	2.45	121.2	130.4
GOOG	21.0	122.5	123.1	2.43	118.3	127.3

Estadística	P05	P10	P25	P50	P75	P90
AMZN	122.8	123.4	124.8	126.6	127.9	129.3
GOOG	118.3	119.1	120.6	123.1	123.7	125.1

Descripción

Analizar si las siguientes afirmaciones son verdaderas o falsas. Justificar

- a. El nivel medio de la cotización de AMZN es mayor al nivel medio de la cotización de GOOG.
Verdadero porque el nivel medio de la cotización de AMZN es 126,4; mientras que el nivel medio de la cotización de GOOG es 122,5.
- b. El nivel de cotización mínima de la mitad de las cotizaciones de AMZN es mayor que el nivel de cotización mínima de la mitad de las cotizaciones de GOOG.
Verdadero porque el nivel de cotización mínima de la mitad (P50) es de 126,6 para AMZN y de 123.1 para GOOG
- c. El nivel de cotización máxima del 25 % de GOOG que tienen menores cotizaciones es mayor al nivel de cotización máxima del 25 % de AMZN que tienen menores cotizaciones.
Falso porque el nivel cotización máxima del 25% (P25) de GOOG que tiene menores cotizaciones es 120.6; mientras que, en el caso de AMZN, este indicador es 124.8
- d. En las cotizaciones de AMZN se observa una mayor variabilidad.
Verdadero porque el desvío (2,45) de AMZN es mayor que en el caso GOOG (2,43).


Descripción

Analizar si las siguientes afirmaciones son verdaderas o falsas. Justificar

e. El nivel de cotizaciones **mínimas** del 25 % superior de las cotizaciones de GOOG es casi similar al nivel de cotizaciones mínimo del 90 % superior de las cotizaciones de AMZN.

Verdadero porque el valor del percentil 10 (123,4) para AMZN es similar al valor del percentil 75 (123,7) de GOOG

P10 me da el valor máximo del 10% o el valor mínimo del 90% superior




f. No existen valores atípicos (ni moderados ni severos) en ambas series.

Verdadero porque en los boxplots no se observan ningún valor atípico.

Descripción

EJEMPLO: Observando el siguiente boxplot para una muestra del PBI anual de Argentina entre 2011-2021 en millones de pesos, completar la siguiente descripción:



La distribución del PBI de Argentina se encuentra sesgada a _____, es decir, con cola a _____ y concentración de datos a _____. Se presenta un valor 624294,9 que es atípico _____. Además se puede observar una _____ variabilidad en la distribución, cuya concentración central se encuentra entre _____ y _____. Dado que el coeficiente de curtosis es 3,42, la distribución del PBI es _____. También, es posible observar que el 75% superior de la distribución del PBI se encuentra por encima de _____.

Pueden realizar la práctica 5