

Análisis Estadístico I

Estadística no paramétrica

Natalia SALABERRY

Test no paramétricos

En toda la inferencia realizada anteriormente suponíamos que conocíamos la distribución original de la variable aleatoria. Pero en ocasiones puede suceder que no haya argumentos suficientes para suponer que se trata de una distribución conocida. Para tales casos, existen métodos generales (en general son test de hipótesis sobre alguna característica) que permiten validar si se trata de tal o cual distribución. Estos se denominan no paramétricos o de libre distribución.

También, podemos validar la independencia de atributos.

Test de Bondad de Ajuste

1. Para una variable aleatoria (discreta o continua)

Estadístico observado
$$x_{obs}^2 = \sum_{i=1}^k \frac{(F_i - E_i)^2}{E_i} \sim \chi_{v; 1-\alpha}^2$$

donde

F_i número de ocurrencias

$E_i = n * p_i$ (n tamaño muestra y p probabilidad)

$v = k - r - 1$ grados de libertad con k=números de valores de X, r=cantidad de parámetros de la distribución (puede ser 0 si no se cuenta con alguna)

Criterio de rechazo: $x_{obs}^2 > \chi_{v; 1-\alpha}^2$ para rechazar H_0

Hipótesis:

H_0 : X sigue una distribución A

H_1 : X no sigue una distribución A

Donde A será la distribución que se supone

Test de Bondad de Ajuste

1. Ejemplo variable aleatoria discreta

Se supone que la cantidad diaria de reclamos sigue una distribución de Poisson. Se tienen los siguientes datos:

Reclamos (k)	0	1	2	3	4
Días (F)	20	62	25	12	1

Ponga a prueba lo supuesto sobre la distribución con $\alpha=0.05$

Resolución:

X="cantidad de reclamos"

Hipótesis:

H0: X sigue una distribución Poisson(λ)

H1: X no sigue una distribución Poisson (λ)

Estadístico observado: $\chi^2_{obs} = \sum_{i=1}^k \frac{(F_i - E_i)^2}{E_i}$

Criterio de rechazo: $\chi^2_{obs} > \chi^2_{v; 1-\alpha}$ para rechazar H0

$$E_i = n * p_i$$

Reclamos (k)	0	1	2	3	4	Total
Días (F)	20	62	25	12	1	120 = n

p_i se calcula con la fórmula de la distribución de Poisson que era: $P(X = k) = \frac{e^{-\lambda} * \lambda^k}{k!}$

Necesitamos λ , que es el valor esperado, es decir, la media

$$\lambda = \frac{\sum_{i=0}^{10} F_i * k_i}{n} = \frac{(0*20)+(1*62)+(2*25)+(3*12)+(4*1)}{120} = \frac{152}{120} = 1,27$$

Luego

$$P(X = 0) = \frac{e^{-1,27} * 1,27^0}{0!} = 0,2808 \quad P(X = 1) = \frac{e^{-1,27} * 1,27^1}{1!} = 0,3567$$

$$P(X = 2) = \frac{e^{-1,27} * 1,27^2}{2!} = 0,2265 \quad P(X = 3) = \frac{e^{-1,27} * 1,27^3}{3!} = 0,0959 \quad P(X = 4) = \frac{e^{-1,27} * 1,27^4}{4!} = 0,0304$$

Reclamos (k)	0	1	2	3	4
Días (F)	20	62	25	12	1
p_i	0,28083162	0,35665616	0,22647666	0,09587512	0,03044035
$E_i = n * p_i$	33,6997946	42,7987392	27,1771994	11,5050144	3,65284207

$$\chi^2_{obs} = \sum_{i=1}^k \frac{(F_i - E_i)^2}{E_i} = \frac{(20 - 33,6997946)^2}{33,6997946} + \frac{(62 - 42,7987392)^2}{42,7987392} + \frac{(25 - 27,1771994)^2}{27,1771994} + \frac{(12 - 11,5050144)^2}{11,5050144} + \frac{(1 - 3,65284207)^2}{3,65284207} = 15,1578565$$

$$\chi^2_{obs} = \sum_{i=1}^k \frac{(F_i - E_i)^2}{E_i} = 5,56930315 + 8,61446914 + 0,17441816 + 0,30719017 = 14,6653806$$

$$\chi^2_{v;1-\alpha} = \chi^2_{k-P-1;1-\alpha} = \chi^2_{4-1-1;1-0.05} = \chi^2_{2;0.95} = 5,991$$

Si bien k=5 en un comienzo, al agruparse datos, quedaron 4 posibilidades. Por esta razón k=4

Como $\chi^2_{obs} = 14,6653806$ es mayor $\chi^2_{3;0.95} = 5,991$ se rechaza la H_0 . Por lo tanto, no hay evidencia suficiente para decir que los reclamos siguen una distribución de Poisson con un 95% de confianza.

Test de Bondad de Ajuste

2. Ejemplo variable aleatoria continua

Se supone que duración de la batería de autos puede asociarse a una distribución Normal con media 3.5 y desvío 0.7. Se han observado en 40 autos la duración de sus baterías obteniéndose los siguientes datos:

Rangos de duración	F (autos)
1,45 a 1,95	2
1,95 a 2,45	1
2,45 a 2,95	4
2,95 a 3,45	15
3,45 a 3,95	10
3,95 a 4,45	5
4,45 a 4,95	3

Ponga a prueba lo supuesto sobre la distribución con $\alpha=0.05$

Resolución:

Hipótesis:

H0: X sigue una distribución Normal

H1: X no sigue una distribución Normal

Estadístico observado: $\chi_{obs}^2 = \sum_{i=1}^k \frac{(F_i - E_i)^2}{E_i}$

Criterio de rechazo: $\chi_{obs}^2 > \chi_{v;1-\alpha}^2$ para rechazar H0

p_i se calcula como:

$$P(Li < x_i < Ls) = P\left(\frac{X - \mu}{\sigma} < Z < \frac{X - \mu}{\sigma}\right)$$

Luego

$$\begin{aligned} P\left(\frac{1.45-3.5}{0.7} < Z < \frac{1.95-3.5}{0.7}\right) &= P(-2.93 < Z < -2.21) = P(Z < -2.21) - P(Z < -2.93) \\ &= [1 - P(Z < 2.21)] - [1 - P(Z < 2.93)] = P(Z < 2.93) - P(Z < 2.21) = 0.9983 - 0.9865 = 0.0118 \\ &= 0.012 \end{aligned}$$

$$\begin{aligned} P\left(\frac{1.95-3.5}{0.7} < Z < \frac{2.45-3.5}{0.7}\right) &= P(-2.21 < Z < -1.5) = P(Z < -1.5) - P(Z < -2.21) \\ &= [1 - P(Z < 1.5)] - [1 - P(Z < 2.21)] = P(Z < 2.21) - P(Z < 1.5) = 0.98645 - 0.93319 = 0.05326 \\ &= 0.0533 \end{aligned}$$

$$\begin{aligned}
 P\left(\frac{2.45-3.5}{0.7} < Z < \frac{2.95-3.5}{0.7}\right) &= P(-1.5 < Z < -0.786) = P(Z < -0.786) - P(Z < -1.5) \\
 &= [1 - P(Z < 0.786)] - [1 - P(Z < 1.5)] = P(Z < 1.5) - P(Z < 0.786) = 0.93319 - 0.78407 \\
 &= 0.14912 = 0.1491
 \end{aligned}$$

$$\begin{aligned}
 P\left(\frac{2.95-3.5}{0.7} < Z < \frac{3.45-3.5}{0.7}\right) &= P(-0.786 < Z < -0.0714) = P(Z < -0.0714) - P(Z < -0.786) \\
 &= [1 - P(Z < 0.0714)] - [1 - P(Z < 0.786)] = P(Z < 0.786) - P(Z < 0.0714) = 0.78407 - 0.52846 \\
 &= 0.25561 = 0.2556
 \end{aligned}$$

$$\begin{aligned}
 P\left(\frac{3.45-3.5}{0.7} < Z < \frac{3.95-3.5}{0.7}\right) &= P(-0.0714 < Z < 0.6429) = P(Z < 0.6429) - P(Z < -0.0714) \\
 &= [P(Z < 0.6429)] - [1 - P(Z < 0.0714)] = 0.73986 - [1 - 0.52846] = 0.26832 = 0.2683
 \end{aligned}$$

$$\begin{aligned}
 P\left(\frac{3.95-3.5}{0.7} < Z < \frac{4.45-3.5}{0.7}\right) &= P(0.6429 < Z < 1.357) = P(Z < 1.357) - P(Z < 0.6429) \\
 &= 0.91261 - 0.73986 = 0.17275 = 0.1728
 \end{aligned}$$

$$\begin{aligned}
 P\left(\frac{4.45-3.5}{0.7} < Z < \frac{4.95-3.5}{0.7}\right) &= P(1.357 < Z < 2.071) = P(Z < 2.071) - P(Z < 1.357) \\
 &= 0.98082 - 0.91261 = 0.06821 = 0.0682
 \end{aligned}$$

IMPORTANTE: este test requiere que la frecuencia absoluta siempre sea mayor que 5. Resulta necesario achicar la cantidad de intervalos agrupando aquellos con una frecuencia menor a dicho valor (se suman los valores).

Rangos de duración	F (autos)	p_i	$E_i = n * p_i$
1,45 a 1,95	2	0.012	$40 * 0.012 = 0.48$
1,95 a 2,45	1	0.0533	$40 * 0.0533 = 2.132$
2,45 a 2,95	4	0.1491	$40 * 0.1491 = 5.964$
2,95 a 3,45	15	0.2556	$40 * 0.2556 = 10.224$
3,45 a 3,95	10	0.2683	$40 * 0.2683 = 10.732$
3,95 a 4,45	5	0.1728	$40 * 0.1728 = 6.912$
4,45 a 4,95	3	0.0682	$40 * 0.0682 = 2.728$

$$\chi^2_{obs} = \sum_{i=1}^k \frac{(F_i - E_i)^2}{E_i} = \frac{(7 - 8,576)^2}{8,576} + \frac{(15 - 10,224)^2}{10,224} + \frac{(10 - 10,732)^2}{10,732} + \frac{(8 - 9,64)^2}{9,64} =$$

$$= 0.2896 + 2.2310 + 0.0499 + 0.279 = 2.8495$$

$$\chi^2_{v;1-\alpha} = \chi^2_{k-1;1-\alpha} = \chi^2_{4-1;1-0.05} = \chi^2_{3;0.95} = 7,815$$

Como $\chi^2_{obs} < \chi^2_{3;0.95}$ no rechazo H_0 . Por lo tanto la distribución $N(3.5;0.7)$ presenta un buen ajuste a la duración de las baterías.

Si bien $k=7$ en un comienzo, al agruparse datos, quedaron 4 posibilidades (y no se restan los parámetros). Por esta razón $k=4$

Test de independencia de atributos

Las frecuencias observadas en cada uno de los atributos se presentan en una Tabla de Contingencia con dos criterios de clasificación:

A/B	B_1	B_2	$\dots$	B_j	$\dots$	B_s	Totales
A_1	n_{11}	n_{12}	$\dots$	n_{1j}	$\dots$	n_{1s}	$n_{1.}$
A_2	n_{21}	n_{22}	$\dots$	n_{2j}	$\dots$	n_{2s}	$n_{2.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
A_r	n_{r1}	n_{r2}	$\dots$	n_{rj}	$\dots$	n_{rs}	$n_{r.}$
Totales	$n_{.1}$	$n_{.2}$	$\dots$	$n_{.j}$	$\dots$	$n_{.s}$	n

Donde A, B son los atributos, n_{ij} las frecuencias absolutas observadas conjuntas

Estadístico observado $\chi^2_{obs} = \sum_{i=1}^s \sum_{j=1}^r \frac{(n_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{v; 1-\alpha}$

donde

$$E_{ij} = \frac{n_{i.} n_{.j}}{n}$$

$v = (r - 1) * (s - 1)$ grados de libertad
con r N° de filas, s N° de columnas

Criterio de rechazo: $\chi^2_{obs} > \chi^2_{v; 1-\alpha}$ para rechazar H0

Hipótesis:

H0: los atributos A y B son independientes

H1: los atributos A y B no son independientes

En caso de que $E_{ij} < 5$, se aplica un ajuste al estadístico observado $\chi^2_{obs} = \sum_{i=1}^s \sum_{j=1}^r \frac{(|n_{ij} - E_{ij}| - 0,5)^2}{E_{ij}}$

Ejemplo

Con el objetivo de dirigir eficientemente la publicidad para neutralizar a la competencia, una empresa productora de artículos de consumo masivo ha realizado una encuesta sobre la preferencia del público en distintas zonas, obteniendo los siguientes resultados:

Preferencia	Zonas				
	A	B	C	D	E
Empresa	35	22	28	33	16
Competencia	45	28	12	17	24

¿Considera que existe evidencia para afirmar que la preferencia y la zona están asociadas? utilice $\alpha=0.05$

Resolución:

Hipótesis:

H0: la preferencia y la zona son independientes

H1: la preferencia y la zona no son independientes

Estadístico observado: $\chi^2_{obs} = \sum_{i=1}^s \sum_{j=1}^r \frac{(n_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{v; 1-\alpha}$

Criterio de rechazo: $\chi^2_{obs} > \chi^2_{v; 1-\alpha}$ para rechazar H0

Marca preferida	Zonas					
	A	B	C	D	E	Total
Empresa	35	22	28	33	16	134
Competencia	45	28	12	17	24	126
Total	80	50	40	50	40	260

$$\begin{aligned}
 E_{11} &= \frac{n_A \cdot n_{\text{empresa}}}{n} = \frac{80 \cdot 134}{260} = 41,23 & E_{12} &= \frac{n_A \cdot n_{\text{competencia}}}{n} = \frac{80 \cdot 126}{260} = 38,77 \\
 E_{21} &= \frac{n_B \cdot n_{\text{empresa}}}{n} = \frac{50 \cdot 134}{260} = 25,77 & E_{22} &= \frac{n_B \cdot n_{\text{competencia}}}{n} = \frac{50 \cdot 126}{260} = 24,23 \\
 E_{31} &= \frac{n_C \cdot n_{\text{empresa}}}{n} = \frac{40 \cdot 134}{260} = 20,62 & E_{12} &= \frac{n_C \cdot n_{\text{competencia}}}{n} = \frac{40 \cdot 126}{260} = 19,38 \\
 E_{41} &= \frac{n_D \cdot n_{\text{empresa}}}{n} = \frac{50 \cdot 134}{260} = 25,77 & E_{22} &= \frac{n_D \cdot n_{\text{competencia}}}{n} = \frac{50 \cdot 126}{260} = 24,23 \\
 E_{51} &= \frac{n_E \cdot n_{\text{empresa}}}{n} = \frac{40 \cdot 134}{260} = 20,62 & E_{12} &= \frac{n_E \cdot n_{\text{competencia}}}{n} = \frac{40 \cdot 126}{260} = 19,38
 \end{aligned}$$

Resolución:

$$\chi^2_{obs} = \sum_{i=1}^s \sum_{j=1}^r \frac{(n_{ij} - E_{ij})^2}{E_{ij}} =$$

$$\frac{(35-41,23)^2}{41,23} + \frac{(45-38,77)^2}{38,77} + \frac{(22-25,77)^2}{25,77} + \frac{(28-24,23)^2}{24,23} + \frac{(28-20,62)^2}{20,62} + \frac{(12-19,38)^2}{19,38} + \frac{(33-25,77)^2}{25,77} + \frac{(17-24,23)^2}{24,23} + \frac{(16-20,62)^2}{20,62} + \frac{(24-19,38)^2}{19,38} = 14,86$$

$$\chi^2_{v=(2-1)*(5-1); 1-0.05} = \chi^2_{4;0.95} = 9,4877$$

Donde r es el número de filas = 2 y s es el número de columnas = 5

Como $\chi^2_{obs} = 14.86 > \chi^2_{4;0.95} = 9,4877$, rechazo H_0 . Por lo tanto, hay evidencia suficiente para suponer que los atributos no son independientes (la preferencia depende de la zona) con un 95% de confianza.

Pueden realizar de la práctica 8